General Course of Artificial Intelligence



人工智能通识

第三章 机器学习基础（上）

2026年秋季学期

https://ai4ge.github.io/

课程教材

《人工智能通识（公共课版）》

机械工业出版社

主　编：黄 栋、黄 琼、裴颂文

ISBN：978-7-111-82285-1



回顾上一次课

- 什么是人工智能？
- 人工智能的发展历程
- 大模型时代下的人工智能
- 人工智能未来展望

第二章

机器学习基础（上）

教学目录

- 机器学习基本概念
- 主要术语与任务分类
- 机器学习的三要素
- 关键概念辨析

机器学习的本质是什么?

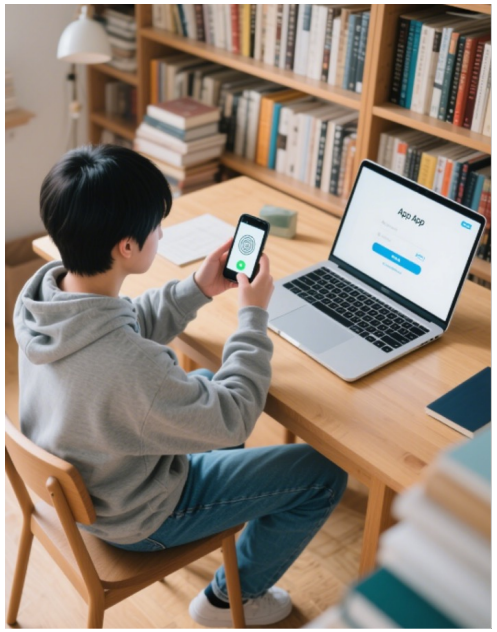
这既是伏笔，也是贯穿始终的核心问题

引入：

一个案例、两个流派

身边的“机器学习”





你每天用几次人脸识别解锁手机？

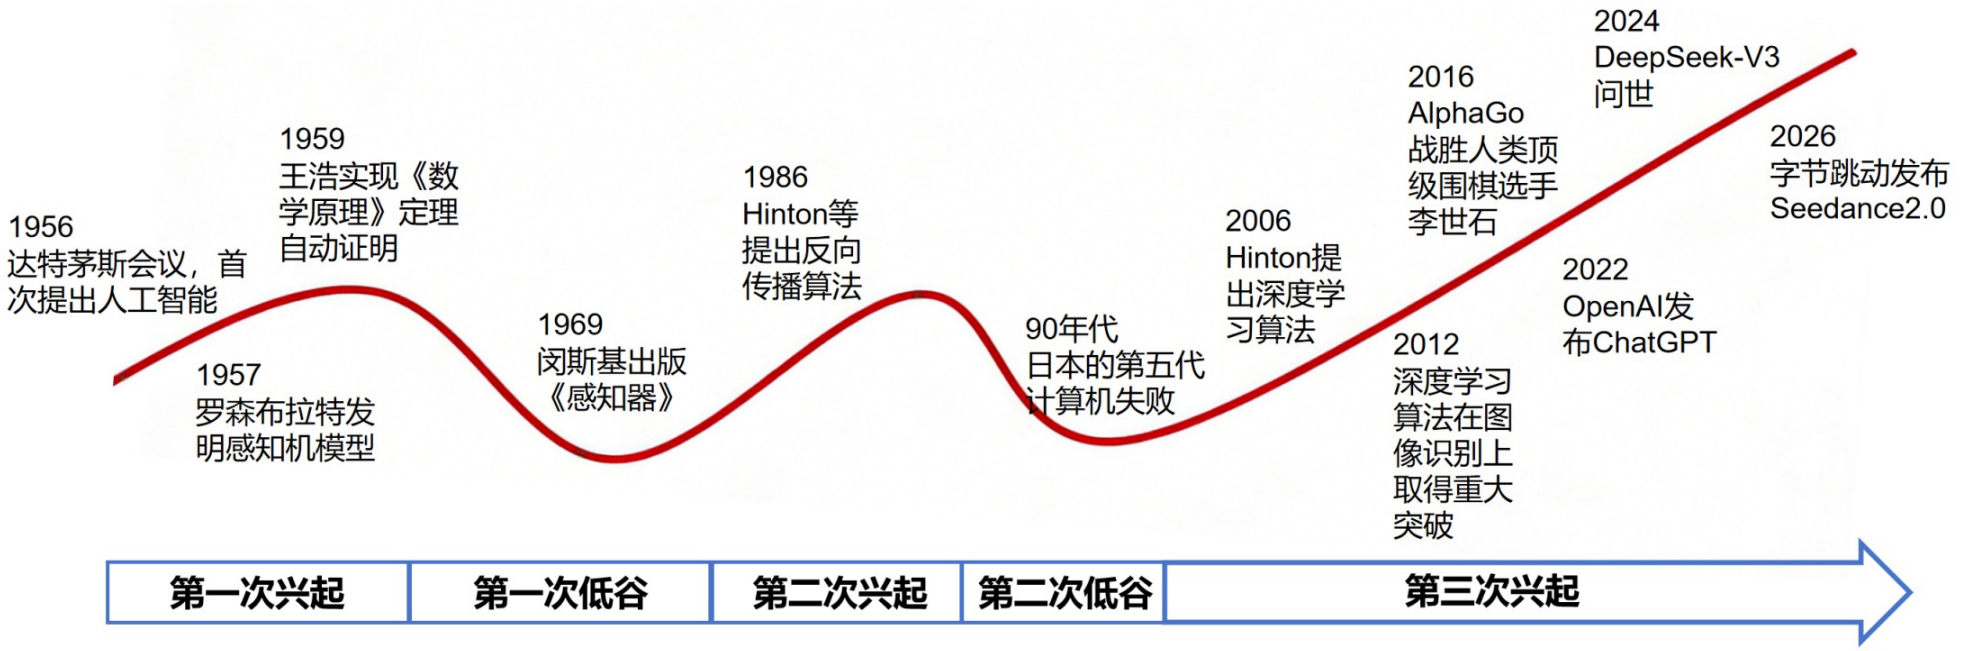
思考一下**手机为什么能识别出你的脸？**

带着这个问题，

先了解人工智能的两个流派

稍后回来…

两个历史流派



- **人工智能的两个历史流派**
  - **符号主义**（又称逻辑主义）：早期主流 ⇨ **规则驱动**
  - **连接主义**：近三十余年占据主导 ⇨ **数据驱动**

人工智能通识教程（公共课版）主编：黄栋 等

符号主义（规则驱动）

- **核心思想**：模仿人类逻辑，认为“智能”源于对符号（概念）的操纵和基于规则的推理，可视作通过一系列“如果...那么...”的逻辑规则来实现。
- **例如：如何识别猫？**
  - 人类专家先定义好规则：
    - ✓ 如果 它有尖耳朵 那么 加10分
    - ✓ 如果 它有胡须 那么 加10分
    - ✓ 如果 它的眼睛是竖瞳 那么 加15分
    - ✓ 如果 它会“喵喵”叫 那么 加20分
    - ✓ ...
  - 电脑接收到一个对象后，就一条一条地核对这些规则，进行逻辑推理和计算。
  - **如果**总分超过50分，**那么**就判定它是猫。

符号主义的局限：柏拉图的故事

- 柏拉图曾给人下过一个定义：两条腿走路的就叫人。
- 某学生抓来了一只鸡，说：老师，这就是你的“人”。
- 柏拉图于是对定义进行了补充：两条腿走路，并且没有羽毛的就是人。
- 次日，学生又抱来一只拔了毛的鸡：老师，这就是你定义的“人”。

规则驱动虽然符合人的直觉，但依赖专家预设的规则体系，试图用有限离散规则描述连续开放世界，可能陷入“补充规则→新反例”的循环困境

回顾两次“AI寒冬”

人工智能通识教程（公共课版）王万森 贾栋 等

连接主义（数据驱动）

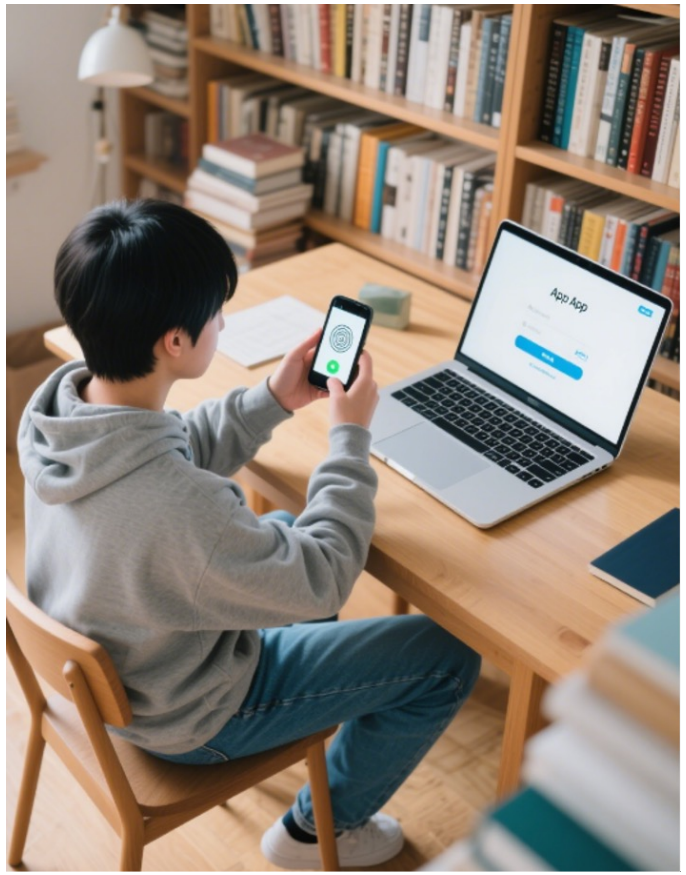
- **核心思想**：模仿大脑结构，认为“智能”源于大量简单处理单元（神经元）相互连接形成的网络中，通过调整连接强度（权重）来学习模式，可视作一个从海量数据中自动统计和学习规律的模型。

- **又例如：如何识别猫？**
  - 我们不告诉电脑任何关于猫的规则；
  - 直接给它看成千上万张图片（数据），并告诉它哪些是猫（标签1），哪些不是猫（标签0）；
  - 模型（例如神经网络）自己从这些数据中统计和学习出“猫”的抽象模式（比如什么样的像素组合大概率是猫）；
  - 学习完成后，给出一张或一组不曾见过的新图片，模型自动计算出“是不是猫”的概率；如果需评估模型性能，在计算出每张图片是不是猫之后，可得出其“准确率”。

训练阶段	测试阶段 (推理阶段)

再回顾人脸识别的例子

人脸识别



人工区分：如果用语言区分两个人，你会怎样表述？

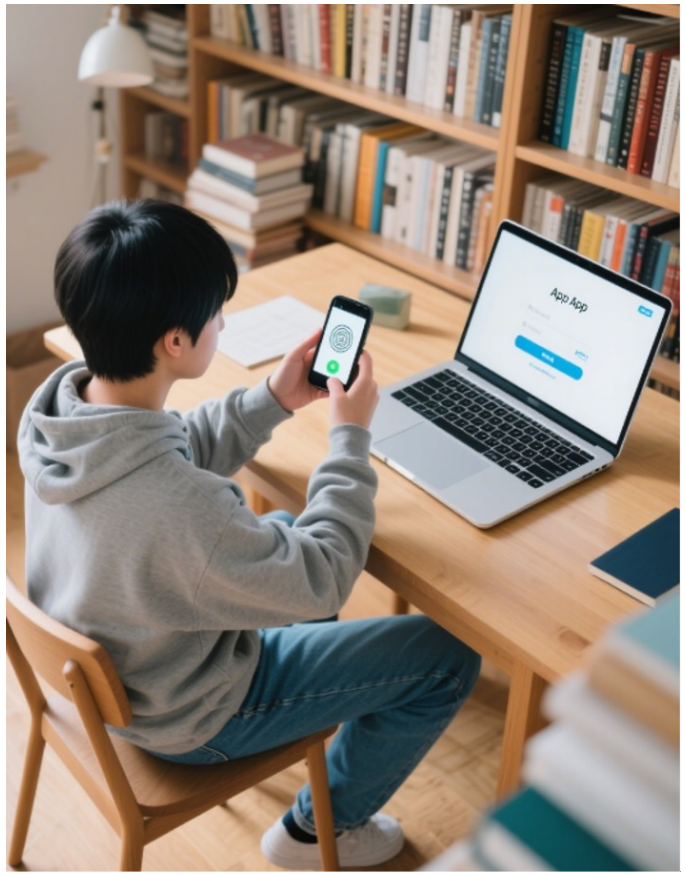
或说：额头有痣、戴眼镜者为张三，否则为李四

——可理解为规则驱动式表述

若区分两人，是否有痣、戴眼镜的规则足矣！

若千万人，是否还能用有限规则区分？

人脸识别



机器学习：

输入数据：人脸图像

输出结果：身份判断（标签）

介于输入与输出之间是什么？机器学习模型

机器学习模型：构建输入数据与预测值之间的映射

更多问题：输入数据怎样表示？预测值怎样表示？两者的映射怎样学习？

人工智能通识教程（公共课版）主编：黄栋 等

2.1 机器学习基本概念

教学重点与难点

教学重点

- 数据集、样本、特征、标签、训练集、测试集、模型的定义及在应用案例中的具体理解。
- 有监督学习（带标签）、无监督学习（无标签）、半监督学习（部分标签）的基本概念。

教学难点

- 特征工程 VS 特征学习
- 理解机器学习的本质
- 理解训练阶段与测试(推理)阶段，了解训练集、测试集

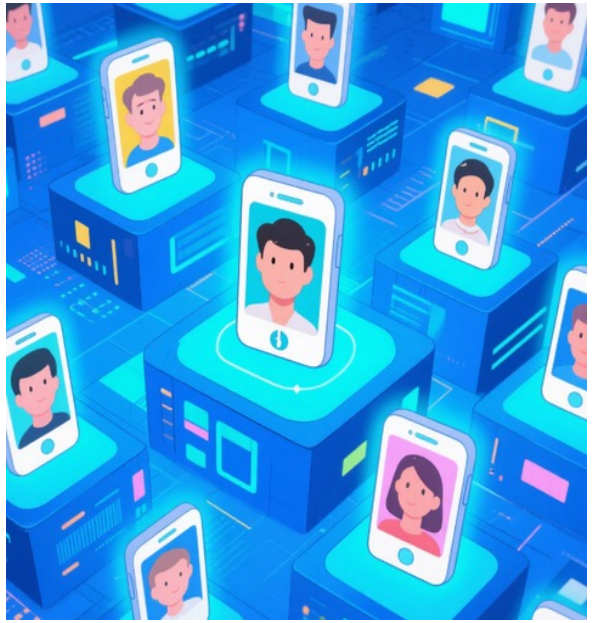
机器学习基本概念

- **机器学习（Machine Learning，ML）**是以计算机模拟或实现人类的学习行为、自动从数据中学习规律的过程。
- 换言之，机器学习是一种从观察到的数据（样本）中发现规律，并利用学到的规律（模型）对未观察到的位置和数据进行预测的方法，是人工智能的一类基础技术。

训练	测试 (推理)

机器学习基本概念

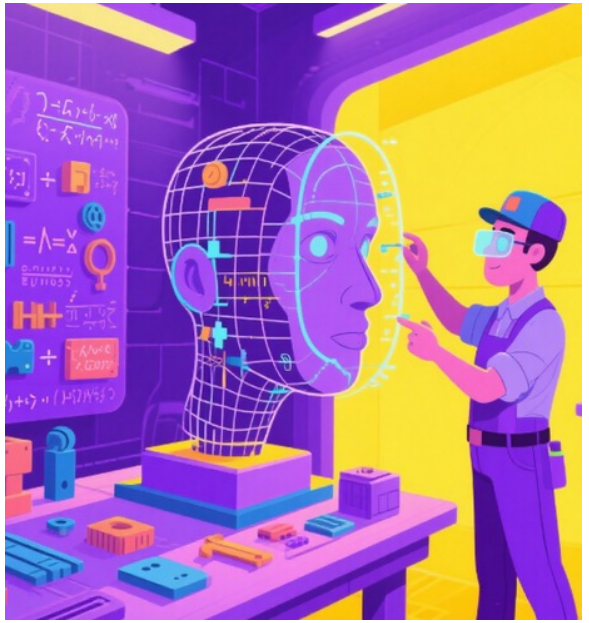
机器学习的核心：让计算机从数据和经验中学习规律



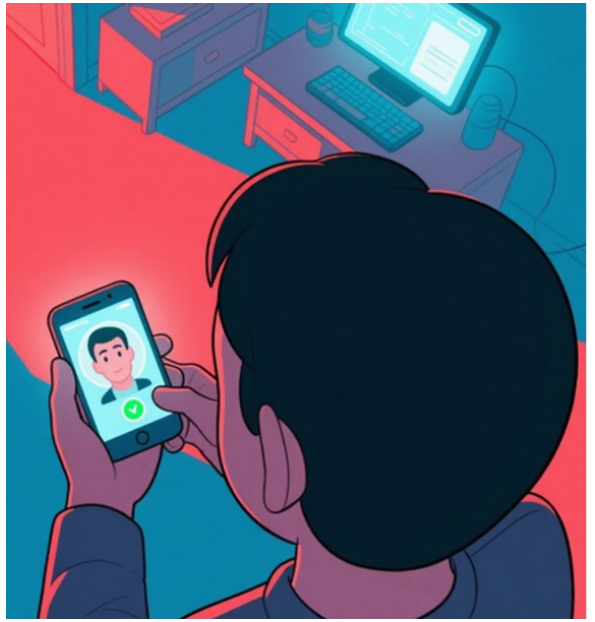
从大量样本中获取“经验”（例如一组用于学习的人脸图像）



从数据中学习有用的特征和规律



建立模型，并通过训练不断优化模型参数



最终实现对未知情况的判断（识别新照片是否机主）

以人脸识别为例，我们无需人工写出“怎样识别人脸”的每一条规则，而是让模型从人脸数据中学习有区分度的特征表示，并利用这些特征对新的输入作出判断。

主要术语介绍

数据集

- **数据集（Dataset）**：由一组用于机器学习的数据样本组成的集合，其中每一个独立的数据对象称为一个“样本”（Sample）或“示例”（Instance）

思考：在人脸识别的例子中，什么是“数据集”？什么又是一个“样本”？

数据集

- 在人脸识别任务中，**人脸数据集**是由大量人脸样本组成的数据集合，可用于模型的训练、验证或测试。其中，每一张人脸图像可以看作一个**样本**。



特征

- **特征（Feature）：**特征是输入变量，反映事件或对象在某些方面的表现或性质，又称“属性”（Attribute）。
- 机器学习模型正是利用这些特征，寻找不同样本之间的规律，并据此作出预测或判断。

思考：一张人脸图像输入计算机后，机器究竟根据什么信息来区分不同的人？

特征

- 在人脸识别中，“特征”是模型用来表示和区分不同人脸的信息。
  - 简单情况下，人们可以人工设计一些容易理解的特征，例如眼睛间距、脸部轮廓、局部纹理等。[特征工程]
  - 现代深度学习系统则更多由模型直接从人脸图像中自动学习高维、抽象的特征表示，而不需要人工逐项规定“应该看哪些特征”。[特征学习]



特征工程与特征学习

- **特征工程（Feature Engineering）**

  由人根据领域知识，对原始数据进行特征的提取、选择和构造，再将这些特征输入模型进行学习。

- **特征学习（Feature Learning）**

  由模型在训练过程中自动从数据中学习适合任务的特征表示，不再需要人工逐项规定“应该提取哪些特征”。

从特征工程到特征学习，本质上是由“人工设计特征”逐步走向“模型自动学习特征表示”

标签

标签（Label）：在监督学习中，标签是训练样本对应的真实目标或“正确答案”。模型根据样本的输入特征进行预测，得到相应的预测结果。

根据样本是否具有标签，数据可以分为有标签数据和无标签数据。

思考：在人脸识别的例子中，一张人脸图像的“标签”是什么？

标签

- **在人脸识别中**，标签（Label） 就是我们要让机器学习模型去预测或判断的**“这张脸是谁？”的答案**
- 在人脸识别的二分类例子中，标签表示一张人脸图像对应的真实身份类别，即“机主”（标签1）或“非机主”（标签0）。



模型

模型（Model）：模型可以简单理解为机器通过训练“学会的一套映射规律”。它接收样本的特征作为输入，并据此给出预测结果。

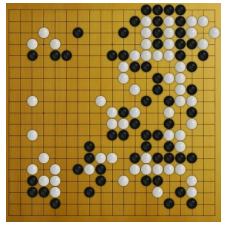
如果有10张机主照片、90张非机主照片，“完美”机器学习模型输出值应是什么？

机器学习的本质

机器学习的本质

机器学习的本质是寻找（学习）一个映射函数：

图像分类 $f($  $)=$ “熊猫”

围棋 $f($  $)=$ “6-5”（落子位置）

语音识别 $f($  $)=$ “你好”

机器学习的本质

机器学习的本质是寻找（学习）一个映射函数：

$$Y = f(X)$$

输出：预测值

分类（多分类、二分类）

回归（输出一个连续值）

模型

模型即函数，

但如何学习？

输入：数据样本

结构化的原始数据，

或提取的特征

机器学习的本质

机器学习的本质是寻找（学习）一个映射函数：

$$Y = f(X)$$

输出：预测值

分类（多分类、二分类）

回归（输出一个连续值）

例如：对于三分类（猫、狗、鸟），预测值 Y 是一个 3 维向量，对应于样本 X 属于三类的概率（猫:0.7、狗:0.2、鸟:0.1）

那对于二分类问题和回归问题呢？

机器学习的本质

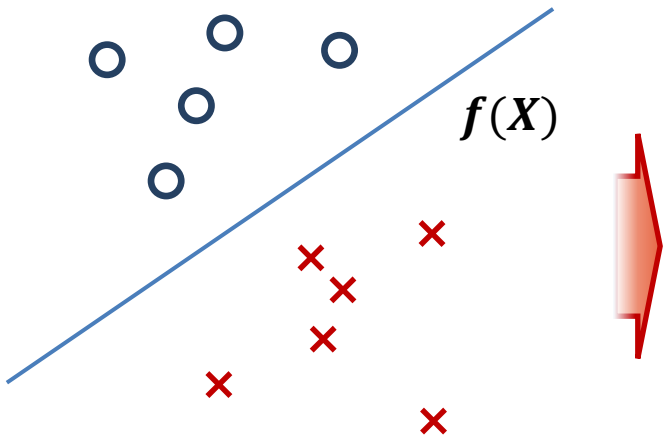
机器学习的本质是寻找（学习）一个映射函数：

$$Y = f(X)$$

输入：数据样本

不妨简化为 2 维情况

目标：寻找二维平面上的一个分割线



该分割线 $y = ax + b$ 即为一个分类模型（分类器），其模型参数量为2

若无法线性划分呢？则需更复杂函数（分割曲线/曲面），带来更大参数量

问题一：参数量是什么意思？（例如大模型）

问题二：怎样学出这些参数？（即模型训练）

人工智能通识教程（公共课版）主编：黄栋 等

机器学习的本质

在人脸识别的例子中，模型即手机内置的人脸识别算法，其**本质是函数映射f**，接收特征向量X（人脸信息），输出判断结果Y（是机主/非机主）。



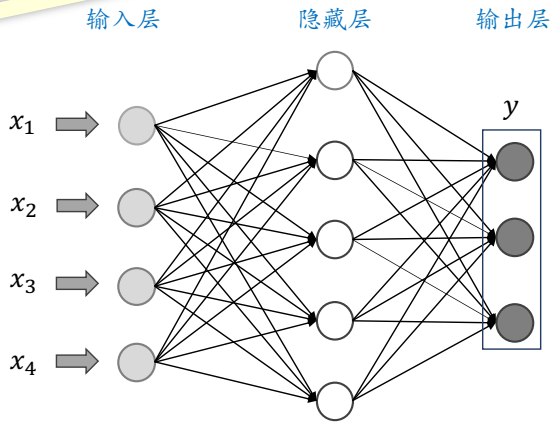
模型训练：以神经网络为例

模型参数

$$Y = f(\theta, X)$$

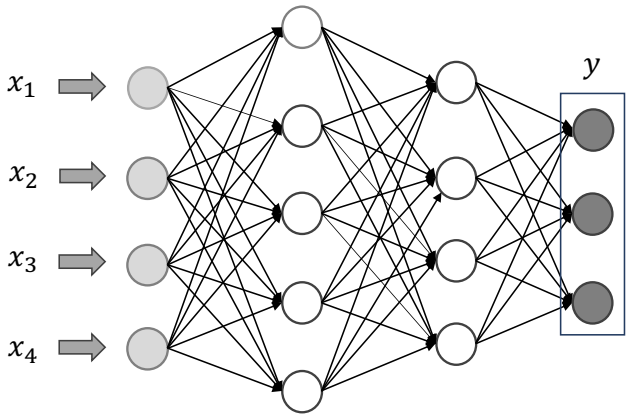
模型

以神经网络为例，怎样进行模型训练？



三层神经网络

（传统网络）



深度神经网络

（层数大于3即为深度）

人工智能通识教程（公共课版）主编：黄栋 等

模型训练：以神经网络为例

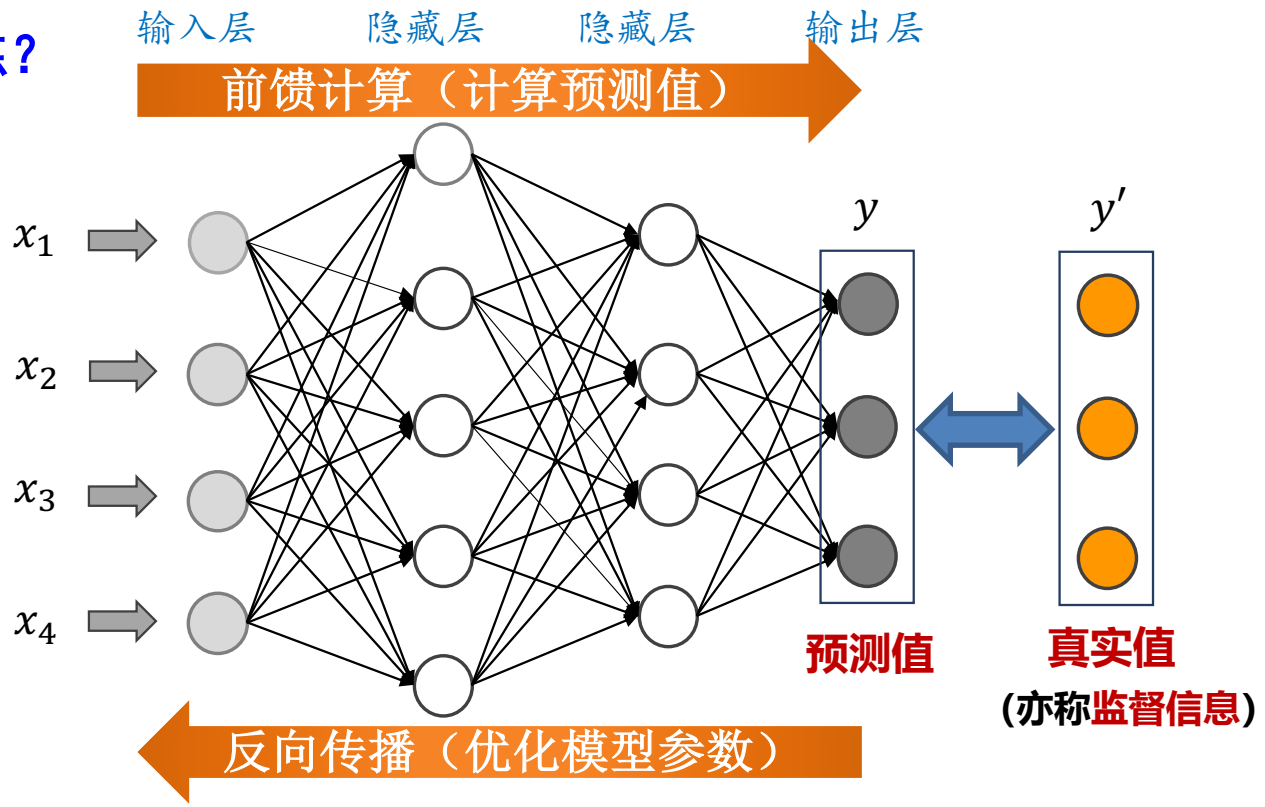
机器学习模型如何训练？

$$Y = f(\theta, X)$$

模型

以神经网络为例，

怎样进行模型训练？



模型训练的目标：

✓ 通过学习，不断让预测值趋近真实值

How?

➢ 定义一个损失函数，度量 y 与 y' 差异

➢ 不断降低损失函数值.

拓展了解，不要求掌握

1. **前馈计算**（Feed-forward computation），计算预测值：$y = f(\theta, x)$
2. **反向传播**（Back-propagation），优化模型参数：$minimize\ L(y, y')$，即调整θ 以减小其差异：

$$\min_{\theta} L(f(\theta, x), y')$$

人工智能通识教程（公共课版）主编：黄栋 等

训练集 VS 测试集

训练集（Training Set）

用于训练模型，通过反复学习数据中的规律来调整模型内部的参数

验证集（Validation Set）

从训练集中拆分出来（并非必须），指导模型调优，但不直接参与模型参数更新

测试集（Test Set）

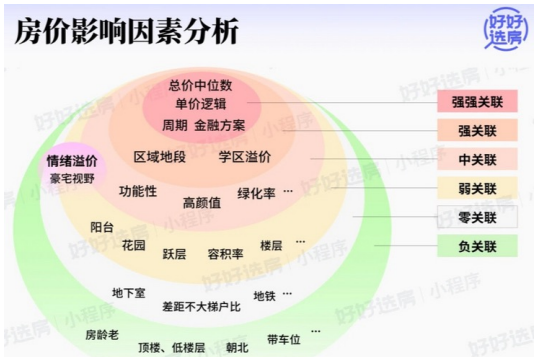
- 评估模型的真实能力，测试在未知数据中的性能
- 仅在最终评估阶段使用，不能参与模型训练或调优

小结

机器学习的本质是寻找（学习）一个映射函数：Y=f(X)

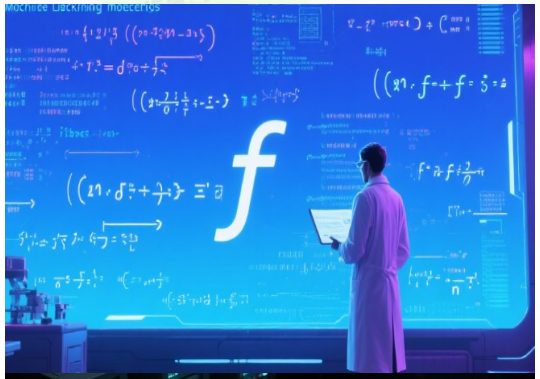
- **X： 输入数据（特征）**

  描述对象的已知信息，是模型作出预测的依据。例如，预测房价时使用的房屋面积、地段、楼层等。



- **f：模型**

  通过训练学到的输入与输出之间的映射关系。例如，根据历史房屋信息和成交价格，学会如何预测房价。



- **Y：输出结果（标签）**

  根据输入信息给出的预测结果，可以是一个类别，也可以是一个数值。例如，模型预测的房价。



预览

机器学习的任务分类

机器学习的任务分类

- 根据训练数据是否包含标签（监督信息），机器学习主要分为以下几类：
  - 有监督学习
  - 无监督学习
  - 半监督学习



谢谢！

https://ai4ge.github.io/